

# Sztuczna inteligencja. Dekompozycja więzów oraz lokalne szukanie rozwiązań

Paweł Rychlikowski

Instytut Informatyki UWr

30 marca 2018

## Przypomnienie

**Reifikacja** – wprowadzanie więzów typu  $X \Leftrightarrow c(Y_1, \dots, Y_n)$ .

- Możemy **ponazywać** sobie wszystkie więzy.
- A następnie kontrolować liczbę spełnionych więzów (dodając warunki: co najmniej 1, co najwyżej 5, więcej tych, niż tych, itd)

## Uwaga


W niektórych systemach są na to osobne więzy globalne, **alleast**, **almost**, **exactly**

## Uwaga


Patrząc na graf więzów, możemy zauważyć pewne właściwości. Na przykład podzielić więzy graf na spójne składowe i rozwiązać je osobno (Tasmania!).

## Uwaga 2

Inną ważną klasą grafów są drzewa. CSP o strukturze drzewiastej da się łatwo rozwiązać. Jak?



- 1 Sortujemy topologicznie drzewo
- 2 Osiągamy spójność łukową (algorytm AC-3)
- 3 Rozwiązujemy szybko taką sieć więzów, zaczynając od korzenia.



## Algorytm

Trywialny: idziemy od lewej do prawej, wybieramy dowolne wartości z dostępnych w danym momencie.


Pamiętajmy o gwarancji, jaką daje AC-3!

- Cieszymy się z algorytmu na drzewach, ale jak sprawić, by CSP stało się drzewem?
- I czy zawsze się da?

## Uwaga

Pamiętajmy, że CSP jest NP-zupełne, a nie spodziewamy się wielomianowego algorytmu dla takich problemów!

Można usunąć jakiś węzeł (węzły)



Popatrzmy na Australię:

- Usunięcie węzła to przypisanie wartości zmiennej (i sprawdzenie innych wartości w kolejnych nawrotach)
- Problem **cycle cutset**
- Używane również w przetwarzaniu sieci bayesowskich


# Cutset conditioning

- **Cutset conditioning** jest metodą wyznaczania **zbioru udrzewiającego** (od którego zaczniemy przypisywanie)
- Powiedzmy, że szukamy zbioru o wielkości  $c$ . Metoda jest następująca:
  1. Wybieramy zbiór zmiennych, które udrzewią problem (czyli po usunięciu graf jest drzewem).
  2. Dla każdego podstawienia, spełniającego więzy z wybranymi zmiennymi usuń w pozostałych dziedzinach wartości niezgodne z wybranym podstawieniem
  3. Rozwiąż pozostały problem (drzewiasty)
- Daje to wielomianowy algorytm dla całego zbioru więzów (przy założeniu stałego  $c$ ).



# Dekompozycja drzewa

- Dzielimy problem na podproblemy, rozwiązywane osobno
- Trywialny przykład: Australia i Tasmania
- Mniej trywialna dekompozycja:



# Warunki dekompozycji drzewa

Dzielimy problem na osobne (potencjalnie powiązane) podproblemy.

## Warunki

1. Każda zmienna jest w co najmniej jednym podproblemie.
2. Nie gubimy więzów: jeżeli dwie zmienne występują w jednym więzie, wówczas muszą znajdować się (z tym więzem) w jakimś podproblemie
3. Jeżeli zmienna występuje w dwóch podproblemach (A i B), to występuje w każdym podproblemie na ścieżce pomiędzy.

# Dekompozycja drzewa (2)

- Oczywiście interesuje nas możliwie najmniejsza wielkość pobproblemów.
- Można testować różnego rodzaju algorytmy zachłanne, czy heurystyczne.

- Jedno z pierwszych zadań na naszej pracowni to były obrazki logiczne (inspirowane algorytmem WalkSat)
- Spróbujemy uogólnić sobie te idee na dowolne CSP.

# Przeszukiwanie lokalne dla CSP

- Przeszukiwanie lokalne nie próbuje systematycznie przeglądać przestrzeni rozwiązań (ogólniej: przestrzeni stanów)
- Zamiast tego pamięta jeden stan (lub niewielką, stałą liczbę stanów)
- Dla CSP stanem będzie kompletne przypisanie (niekoniecznie spełniające więzy).

# Problemy optymalizacyjne

- W tych problemach szukamy stanu, który maksymalizuje wartość pewnej funkcji (jakość planu).
- Często problemy z twardymi warunkami da się zamienić na problemy optymalizacyjne. Jak?

Można policzyć liczbę złych wierszy (kolumn) w obrazkach logicznych, albo liczbę szachów w hetmanach, albo....

## Uwaga

Możemy myśleć o spełnianiu CSP jako o zadaniu maksymalizacji liczby spełnionych więzów.

Możemy zatem stworzyć algorytm, w którym:

- Zmieniamy tę zmienną, która powoduje niespełnienie największej liczby więzów.
- Wybieramy dla niej wartość, która owocuje najmniejszą liczbą konfliktów.


# Przykład: 8 hetmanów

- Jak wybrać stan? (Wskazówka: powinniśmy umieć łatwo przejść ze stanu do stanu)
- Stan: w każdej kolumnie 1 hetman, Ruch: przesunięcie hetmana w górę lub w dół



Popatrzmy, jak działa **min-conflicts** dla hetmanów.






# Min-conflicts dla hetmanów



# Min-conflicts dla hetmanów



# Min-conflicts dla hetmanów



- Dla planszy  $8 \times 8$  osiąga sukces w 14% przypadków.
- Niby niezbyt dużo, ale możemy go uruchomić na przykład 20 razy, wówczas p-stwo sukcesu to ponad 95%.
- Można dopuszczać pewną liczbę ruchów w bok (czyli, że nie możemy poprawić, ale możemy nie pogorszyć, jak na obrazkach).
- Jak dopuścimy ruchy w bok , to wówczas mamy sukces w 94%

- Każdy więź ma wagę, początkowo wszystkie równe na przykład 1
- Waga więzów niespełnionych cały czas troszkę rośnie.
- Chcemy naprawiać nie **zbiór więzów o liczności  $n$** , ale raczej **zbiór więzów o największej sumarycznej wadze**

Więzy trudne, rzadko spełniane będą miały coraz większy priorytet.

- Wyobraźmy sobie, że mamy problem, który się zmienia (ale w niewielkim stopniu)
- Przykład: obsługa linii lotniczych – bo zamykają się lotniska, pilot może złapać gripę, ...


## On-line CSP

Min-conflicts umożliwia rozwiązywanie tego typu zadań: stan początkowy to **ostatnie dobre** przypisanie.

# Przeszukiwania lokalne (ogólnie)

- Powiemy sobie jeszcze o paru ideach związanych z przeszukiwaniem lokalnym.
- Można je wykorzystywać w zadaniach więzowych, ale nie tylko.

# Krajobraz przeszukiwania lokalnego





**Hill climbing** jest chyba najbardziej naturalnym algorytmem inspirowanym poprzednim rysunkiem.

- Dla stanu znajdujemy wszystkie następniiki i wybieramy ten, który ma największą wartość.
- Powtarzamy aż do momentu, w którym nie możemy nic poprawić

## Problem

Oczywiście możemy utknąć w lokalnym maksimum.

# Hill climbing z losowymi restartami

## Uwaga

Możemy podjąć dwa działania, oba testowaliśmy w obrazkach logicznych:

1. Dorzucać ruchy niekoniecznie poprawiające (losowe, ruchy **w bok**)
2. Gdy nie osiągamy rozwiązania przez dłuższy czas rozpoczynamy od początku.

Hill climbing + random restarts (w trywialny sposób) jest algorytmem zupełnym z p-stwem 1 (bo kiedyś wylosujemy układ startowy)

- a) **Stochastic hill climbing** – wybieramy losowo ruchy w górę (p-stwo stałe, albo zależne od wielkości skoku).
- b) **First choice hill climbing** – losujemy następnika tak długo, aż będzie on ruchem w górę
  - dobre, jeżeli następników jest bardzo dużo

## Uwaga

Idee z tego i kolejnych algorytmów można dowolnie mieszać – na pewno coś wyjdzie!

- Motywacja fizyczna: ustalanie struktury krystalicznej metalu.
- Jeżeli będziemy ochładzać powoli, to metal będzie silniejszy (bliżej globalnego minimum energetycznego).
- **Symulowane wyżarzanie** – próba oddania tej idei w algorytmie.

## Algorytm

Symulujemy opadającą temperaturę, prawdopodobieństwo ruchu chaotycznego zależy **malejąco** od temperatury.

## Symulowane wyżarzanie (2)

- Przykładowa implementacja bazuje na **first choice hill climbing**.
- Jak wylosowany jest lepszy  $\Delta F > 0$ , to do niego przechodzimy (maksymalizacja  $F$ ).
- W przeciwnym przypadku wykonujemy ruch z p-stwem  $p = e^{\frac{\Delta F}{T}}$
- Pilnujemy, żeby  $T$  zmniejszało się w trakcie działania (i było cały czas dodatnie)

### Komentarze do wzoru

- $\Delta F \leq 0$ ,  $T > 0$ , czyli  $0 \leq p \leq 1$ .
- Im większe pogorszenie, tym mniejsze p-stwo
- Im większa temperatura, tym większe p-stwo.

## Problem

Być może płaskie maksimum lokalne.

## Rozwiązanie

Dodajemy pamięć algorytmowi, zabraniamy powtarzania ostatnio odwiedzanych stanów.

# Local beam search

- Zamiast pamiętać pojedynczy stan, pamiętamy ich  $k$  (wiązkę).
- Generujemy następniki dla każdego z  $k$  stanów.
- Pozostawiamy  $k$  liderów.

## Uwaga 1

To nie to samo co  $k$  równoległych wątków hill-climbing (bo uwaga algorytmu może przerzucać się do bardziej obiecujących kawałków przestrzeni)

## Uwaga 2

Beam search jest bardzo popularnym algorytmem w różnych zadaniach wykorzystujących sieci neuronowe do modelowania sekwencji (np. tłumaczenie maszynowe).

- Zarządzamy **populacją** osobników (czyli np. pseudorozwiązań jakiegoś problemu więzowego).
- Mamy dwa rodzaje operatorów:
  - a) Mutacja, która z jednego osobnika robi innego, podobnego.
  - b) Krzyżowanie, która z dwóch osobników robi jednego, w jakiś sposób podobnego do „rodziców”.
- Nowe osobniki oceniane są ze względu na wartość **funkcji przystosowania**
- Przeżywa  $k$  najlepszych.

## Uwaga


Zauważmy, że choć zmienił się język, jeżeli pominiemy krzyżowanie, to otrzymamy wariant Local beam search (mutacja jako krok w przestrzeni stanów).



# Krzyżowanie. Przykład

## Pytanie

Czym mogłoby być krzyżowanie dla zadania z  $N$  hetmanami?



1. Krzyżowanie i mutacje można zorganizować tak, że najpierw powstają **dzieci**, a następnie się mutują z pewnym prawdopodobieństwem.
2. Wybór osobników do rozmnażania może zależeć od funkcji dopasowania (większe szanse na reprodukcję mają lepsze osobniki)
3. Można mieć wiele operatorów krzyżowania i mutacji.