

Sztuczna inteligencja. Co dalej?

Paweł Rychlikowski

Instytut Informatyki UWr

14 czerwca 2018

Pytanie: co dalej?

- Rozumienie 1: jakie perspektywy ma AI? Można zgadywać:
 - Znikanie pewnych zawodów, pojawianie się nowych.
 - Rozwój robotyki, uczenia, uczenia ze wzmocnieniem.
 - Lepsza integracja sieci neuronowych z klasycznym wnioskowaniem.
 - Lepsze granie w gry (brydż, RTS, FPS)
 - Lepsza synteza i analiza mowy oraz obrazów
 - Przesunięcie w stronę **przechodzenia testu Turinga**

Lepsze podstawy matematyczne dla różnych metod heurystycznych

- Rozumienie 2: czego można jeszcze się nauczyć o AI w II.

- Popatrzymy na różne przedmioty w II, które mogą być kontynuacją dzisiejszego wykładu.
- Ale żeby nie było całkiem nudno, nie będziemy streszczać przedmiotu.
- W zamian weźmiemy jakiś drobiazg który:
 - a) Jest (lub mógłby być) na danym wykładzie
 - b) Ma związek z naszym wykładem
 - c) Jest (mam nadzieję) ciekawy.
- ... i o nim coś opowiemy.

- **Przedmiot:** Algorytmy metaheurystyczne
- **Wykładowca:** Paweł Rajba

Na tym przedmiocie również: local search, taboo, ewolucyjne przeszukiwanie.

Opowiemy o algorytmie **PSO** (particle swarn optimisation).

Algorytm roju (2)

- Mamy populację **cząstek** (czyli rozwiązań jakiegoś problemu), zakodowanych liczbami **float**
- Szukamy maksimum funkcji, którą potrafimy obliczyć dla cząsteczki (nie musimy znać gradientu).
- Cząstki się poruszają (każda ma wektor prędkości, stąd populację nazywamy **rojem**).
- Pamiętamy:
 1. Najlepsze rozwiązanie do tej pory dla całego roju.
 2. Najlepsze rozwiązanie do tej pory dla każdej cząstki.

Algorytm roju (3)

Algorytm

- a) Zarządzaj położeniem cząstek ($x += v$)
- b) Zarządzaj maksimami: mp (dla czątki) i ms (dla roju)
- c) Zarządzaj prędkościami: $v += c1 * r1 * (mp - x) + c2 * r2 * (ms - x)$ ($r1, r2$ są losowane z przedziału $(0,1)$)

Kończymy na przykład, gdy przez dłuższy czas nie zmieniło się żadne maksimum (ew. nie zmieniło się maksimum globalne).

- **Przedmiot:** Algorytmiczna teoria gier
- **Wykładowca:** Jarosław Byrka

Na tym przedmiocie będzie też między innymi sporo o grach jednoosobowych, równowadze Nasha itd.

- Zamiast tworzyć skomplikowanego agenta, grającego w **trudną grę**
- możemy stworzyć prostego agenta, grającego w **łatwą grę**

Przykład: aukcja

Rozważamy prostą, jednoturową aukcję: oferenci piszą swoje ceny, wygrywa największa, przedmiot sprzedajemy za tę cenę

Co jest nie tak z tą aukcją?

Problemy

Co powinien robić agent, który jest w stanie kupić przedmiot za x ?

- Złożyć ofertę za x ? (jak przegra, to trudno – nie dało się nic zrobić, ale jak wygra, to może przepłaci)
- Złożyć ofertę za $y < x$ (ale jakie y ? Musi modelować innych graczy i być lepszy o ϵ od najlepszego z nich)

A jak działałaby aukcja, w której zwycięzca płaciłby cenę drugą z kolei?

Aukcja: wygrywający płaci drugą cenę

Co jest optymalną strategią gracza dla aukcji Vickreya?

Optymalną strategią jest wypisać swoją cenę i nie przejmować się innymi graczami, bo:

- Jak napiszę za dużo, to być może okaże się niewypłacalny (duża przegrana)
- Nie mam też żadnego interesu w zaniżaniu swojej stawki
- Jak przegram, to znaczy że nie dało się wygrać.
- Jak wygram, to płace troszkę mniej niż $y = x_2 + \varepsilon$.

Deser

Historia o aukcji w Niemczech, Mannesmann vs. T-Mobile
($18.18 * 1.1 = 19.998$)

Pamiętaj, żeby przed przerwą zadać zagadkę!

- **Przedmiot:** Text mining
- **Wykładowca:** Paweł Rychlikowski

- **Przedmiot:** Graph databases
- **Wykładowca:** Piotr Wieczorek

- **Przedmiot:** Tworzenie agentów konwersacyjnych (I1)
- **Wykładowca:** Paweł Rychlikowski

Collaborative filtering



Źródło: Wikipedia

Mamy zbiór obiektów (przedmioty, filmy, książki, ?)


Collaborative filtering



Źródło: Wikipedia

Osoba (obiekt typu 1) lubi/nie-lubi pewnych przedmiotów (obiekty typu 2).


Collaborative filtering



Źródło: Wikipedia

Osób jest oczywiście więcej.


Collaborative filtering



Źródło: Wikipedia

Osób jest oczywiście więcej.


Collaborative filtering



Źródło: Wikipedia

Osób jest oczywiście więcej.


Collaborative filtering



Źródło: Wikipedia

Osób jest oczywiście więcej.










Collaborative filtering



Źródło: Wikipedia

Interesuje nas rekonstrukcja brakującego połączenia.














Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.

















Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.




















Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.






















Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.

























Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.


























Collaborative filtering

Źródło: Wikipedia

Zapisujemy relację w macierzy, w której wiersze to osoby, a kolumny to obiekty.


























Collaborative filtering

Źródło: Wikipedia

Chcemy wypełnić jedno pole w tej macierzy (wydedukować informacje o związku pewnej osoby z pewnym przedmiotem)


























Collaborative filtering

Źródło: Wikipedia

Szukamy **podobnych** osób do naszego bohatera (czyli z dużą liczbą zgodności i małą liczbą konfliktów preferencji)


Collaborative filtering

Źródło: Wikipedia

Pozwalamy tym podobnym na głosowanie na temat naszej preferencji.

Collaborative filtering



Źródło: Wikipedia

Wynikiem jest wniosek, że nasz bohater nie lubi telewizorów plazmowych (musimy wysłać mu reklamę czegoś innego).

Jaki jest facet

- Możemy w miejsce przedmiotów i osób wstawiać różne obiekty, również abstrakcyjne.
- Możliwe zastosowanie: popatrzymy na **przymiotniki** i **rzeczowniki** występujące obok siebie w korpusie.
- Można na przykład wydedukować, że z korpusu wynika, że **facet** jest (bywa) **leniwy**, mimo że tego połączenia nie ma w korpusie.

Uwaga

Wiedza o tym, że połączenie **leniwy facet** jest bardziej naturalne niż połączenie **lenny facet** może przydać się w wielu zadaniach związanych z interpretacją zaszumionego sygnału językowego (np. rozpoznawanie mowy).

Struktura bazy

Podstawową treścią takich zbiorów danych jak Freebase czy DBPedia są trójki postaci:

`<obiekt1>` `<nazwa-relacji>` `<obiekt2>`

Przykłady (DBPedia)

Albrecht von Graefe

- `był` `naukowcem`
- `był` `lekarzem medycyny`
- `urodził się` `1870-7-20`
- `był` `znany z` `jaskry`

Uzupełnianie bazy

Relacje są (częściowo) pobierane z Wikipedii (np. infoboksy), ale częściowo wpisywane ręcznie, co oznacza luki i niekonsekwencje.

Zobacz prace: Andrew McCallum (i inni):

- Chains of Reasoning over Entities, Relations, and Text using Recurrent Neural Networks
- RelNet: End-to-End Modeling of Entities & Relations
- Compositional Vector Space Models for Knowledge Base Completion

Wizualizacja danych. PCA vs t-SNE

- **Przedmiot:** Eksploracja danych
- **Wykładowca:** Piotr Wnuk-Lipiński

Na tym przedmiocie będzie też o systemach rekomendujących (o których mówiliśmy przed chwilą)


Wizualizacja danych wielowymiarowych

- Często zajmujemy się danymi wielowymiarowymi.
- Ale my lubimy dwa wymiary, żeby zobaczyć je na płaszczyźnie.


Wizualizacja obrazów cyfr (MNIST)

Algorytm t-SNE:

MNIST dataset – Two-dimensional embedding of 70,000 handwritten digits with t-SNE



Porównanie klasycznych metod i nowoczesnych




- **Przedmiot:** Sieci neuronowe i deep learning
- **Wykładowca:** Jan Chorowski

- **Przedmiot:** Algorytmy ewolucyjne
- **Wykładowca:** Piotr Wnuk-Lipiński

O zagadnieniach związanych z tymi przedmiotami trochę mówiliśmy.

- Algorytm NEAT jest przykładem połączenia sieci neuronowych i algorytmów ewolucyjnych.
- Celem jest jednoczesne ustalenie struktury sieci dla danego zadania, jak i dobranie jej wag.

Wielość równoważnych reprezentacji



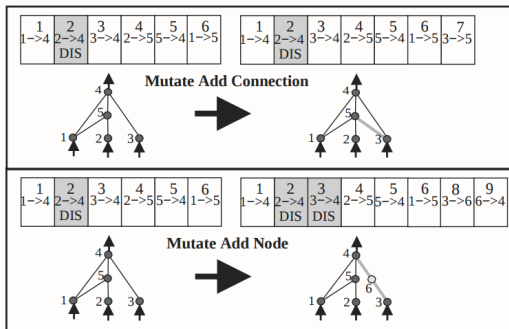
$[A, B, C]$
 $\times [C, B, A]$

Crossovers: $[A, B, A]$ $[C, B, C]$
(both are missing information)

Mutacja struktury sieci

Możliwe są następujące zmiany:


- 1) Dodanie krawędzi między istniejącymi, niepołączonymi węzłami (pilnujemy acykliczności)
- 2) Zmiana wagi na krawędzi
- 3) Dodanie węzła



Każda mutacja pamięta **numer innowacji**

Krzyżowanie (z wykorzystaniem numerów innowacji)

Pilnujemy, żeby numery innowacji się nie powtarzały.



Spacjowanie Pana Tadeusza

- **Przedmiot:** Przetwarzanie języka naturalnego
 - **Wykładowca:** Paweł Rychlikowski
-
- Pamiętamy zadanie z pierwszej listy o wstawianiu spacji w sklejonym tekście.
 - W rzeczywistości rozwiązywalibyśmy je trochę inaczej: korzystając z wiedzy o języku
 - Wiedzę taką możemy nabyć analizując duże zbiory tekstów, tzw. **korpusy**.

Definicja

Model języka określa prawdopodobieństwo tego, że dany ciąg (słów, liter) jest poprawnym napisem języka.

Pozwala wybierać pomiędzy różnymi wariantami wypowiedzi (poprawy literówek, OCR, rozpoznawanie mowy, tłumaczenie)

- Najprostszy model języka to model **unigramowy**: rozważamy prawdopodobieństwo wystąpienia słów.
- Żeby zdecydować jak spacjować **partiachciała** sprawdzamy czy:

$$P(\text{partiach})P(\text{ciała}) > P(\text{partia})P(\text{chciała})$$

- Szacujemy:

$$P(\text{partiach}) \approx \frac{\text{ile razy słowo „partiach” było w korpusie}}{\text{liczba słów w korpusie}}$$

Problemy modelu unigramowego

- Preferuje długie wyrazy (no i ok?) – ew. można temu zaradzić biorąc średnią geometryczną prawdopodobieństwa
- Nie uwzględnia następst wyrazów.

Definicja

W **modelu bigramowym** zakładamy, że:

$$P(w_1 \dots w_n) = P(w_1|[start])P(w_2|w_1) \dots P(w_n|w_{n-1})$$

- Dynamiczny algorytm, wybierający sekwencję maksymalizującą prawdopodobieństwo w modelu bigramowym nazywa się **Algorytmem Viterbiego**
- Bardzo podobny do tego, jak rozwiązywaliśmy zadanie ze spacjowaniem.
- Drobna różnica:
 - a) w zadaniu z listy, wystarczyło pamiętać, jaki jest koszt (i kształt) optymalnej ścieżki kończącej się na danej literce.
 - b) tu musimy pamiętać te dane dla każdej literki i **każdego wyrazu, który może skończyć się w tym miejscu**

Automatyczne tworzenie mechanizmów

- **Przedmiot:** Sztuczna inteligencja w grach
- **Wykładowca:** Jakub Kowalski

Na tym przedmiocie będzie też między innymi sporo o MCTS, MiniMax, $\alpha - \beta$

Zadanie

Stworzyć program, który będzie **odkrywał** ciekawe gry planszowe.

Dwa problemy do rozwiązania:

1. Jak opisać grę planszową?
2. Jak odróżnić fajną grę planszową od słabej? (ciekawsze pytanie)

Ewolucja gier planszowych

Co powinna uwzględniać funkcja oceny?

Kryteria używane w ocenie

- **Wewnętrzne** – jak wygląda opis gry (preferujemy poprawne, niezbyt długie i niezbyt skomplikowane)
- **Grywalność** – zbalansowana dla obu graczy, niezbyt dużo remisów, gry o satysfakcjonującej długości
- **Jakość rozgrywki:**
 - Dramatyzm: wyuczona funkcja oceniająca zmienia wartość w trakcie prawdziwych gier (najlepiej, żeby zmieniała się również przewaga)
 - Nieredukowalność: w rozegranych grach używane są wszystkie rodzaje ruchów
 - Krzywa uczenia: agent uczący się dłużej gra lepiej.

Oczywiście ważnym narzędziem jest TD-learning (żeby powstał jacyś sensowni agenci, których grę możemy analizować).

Jak zarobić na ewolucji gier planszowych

- System **Ludi** służył do ewolucji gier planszowych.
- Podczas tygodnia ewolucji przeanalizowano **1389**, z czego **19** autorzy uznali za grywalne, a dwie, jak piszą **have proven to be of exceptional quality**
- Zapakowali je do pudełka i sprzedawali jako **pierwsze gry planszowe wymyślane przez maszynę**.



Można poczytać w pcgbook.com, rozdział 6

Gra Yavalath

Kod gry

```
(game Yavalath  
  (players White Black)  
  (board (tiling hex) (shape hex) (size 5))  
  (end (All win (in-a-row 4)) (All lose (in-a-row 3))))  
)
```

Przykładowa sytuacja:



- **Przedmiot:** Model checking
- **Wykładowca:** Witold Charatonik

Na przedmiocie będą bardziej logiki temporalne, my też powiemy o logice epistemicznej.

Definicja

Logiki modalne są rozwinięciami logiki zdaniowej o operatory modalności, które wyrażają na przykład:

- Właściwości czasowe (kiedyś, zawsze, jutro)
- Możliwość bądź konieczność czegoś
- Przekonanie lub wiedza agenta o czymś

Dla logiki temporalnej przyjmujemy często następujące aksjomaty (wybór):

- $\Box(\phi \rightarrow \psi) \rightarrow (\Box\phi \rightarrow \Box\psi)$ (\Box oznacza **zawsze**)
- $\Diamond\neg\phi \leftrightarrow \neg\Box\phi$ (\Diamond oznacza **kiedyś**)
- $\bigcirc(\phi \vee \psi) \leftrightarrow \bigcirc\phi \vee \bigcirc\psi$ (\bigcirc oznacza **w kolejnym momencie czasu**)

Dla każdego agenta a dodajemy modalność dotyczącą jego wiedzy, oznaczaną K_a

Przykładowe aksjomaty i ich interpretacja:

- Jak agent zna przesłanki i regułę, to zna też wnioski:

$$K_i\varphi \wedge K_i(\varphi \implies \psi) \implies K_i\psi$$

- Agenci znają tautologie

$$\text{jeżeli } M \models \varphi \text{ to } M \models K_i\varphi.$$

- To co wiemy, jest prawdziwe

$$K_i\varphi \implies \varphi$$

Wiem, że nic nie wiem

- Jak coś wiem, to wiem że to wiem

$$K_i\varphi \implies K_iK_i\varphi$$

- Jak czegoś nie wiem, to wiem że tego nie wiem

$$\neg K_i\varphi \implies K_i\neg K_i\varphi$$

Zagadka z zabłoconymi dziećmi

(na wykładzie był trochę inny wariant)

- ❶ Dzieci są posłuszne, mądre i świadome swej mądrości i posłuszeństwa.
- ❷ Przed Mamusią stoją na baczność, nie dotykają siebie i innych, nie odzywają się niepytane.
- ❸ Wchodzą po zabawie do domu i Mamusia mówi:

Aha, niektóre z was mają błoto na czołach!

- ❹ A następnie prosi:

Niech te z dzieci, które są pewne, że mają zabłocone czoła podniosą rękę.

- ❺ Prośbę powtarza kilka razy, za którymś razem pewna liczba rąk podnosi się do góry.

Polecenie

Wyjaśnij, co się stało.

Wspólna wiedza i najstłynniejsza zagadka logiki epistemicznej

Uwaga

To że ja wiem coś, i ty wiesz, że ja wiem że coś, nie oznacza jeszcze, że ja wiem, że ty wiesz, że ja wiem coś.

- Wprowadza się specjalny operator **wiedzy powszechnej** (common knowledge)
- Definiujemy wiedzę grupową:

$$E_G \varphi \Leftrightarrow \bigwedge_{i \in G} K_i \varphi$$

- Wprowadzamy notację:

$$E_G^n \varphi \text{ definiujemy jako } E_G E_G^{n-1} \varphi$$

$$\text{oraz } E_G^0 \varphi = \varphi$$

- Definiujemy operator:

$$C\varphi \Leftrightarrow \bigwedge_{i=0}^{\infty} E^i \varphi$$

- Zdanie Mamusi (lub Kuglarza) nie jest zdaniem o zerowej informacji: wprowadza ono bowiem do bazy wiedzy wszystkich agentów formułę:

C ktoś-ma-zabłocone-czoło

Próbkowanie Gibbsa i sieci bayesowskie

- **Przedmiot:** Grafowe modele probabilistyczne
- **Wykładowca:** Jan Chorowski

[na tablicy?]